Razonamiento y Planificación Automática

Tema 5. Búsqueda informada

Índice

Esquema

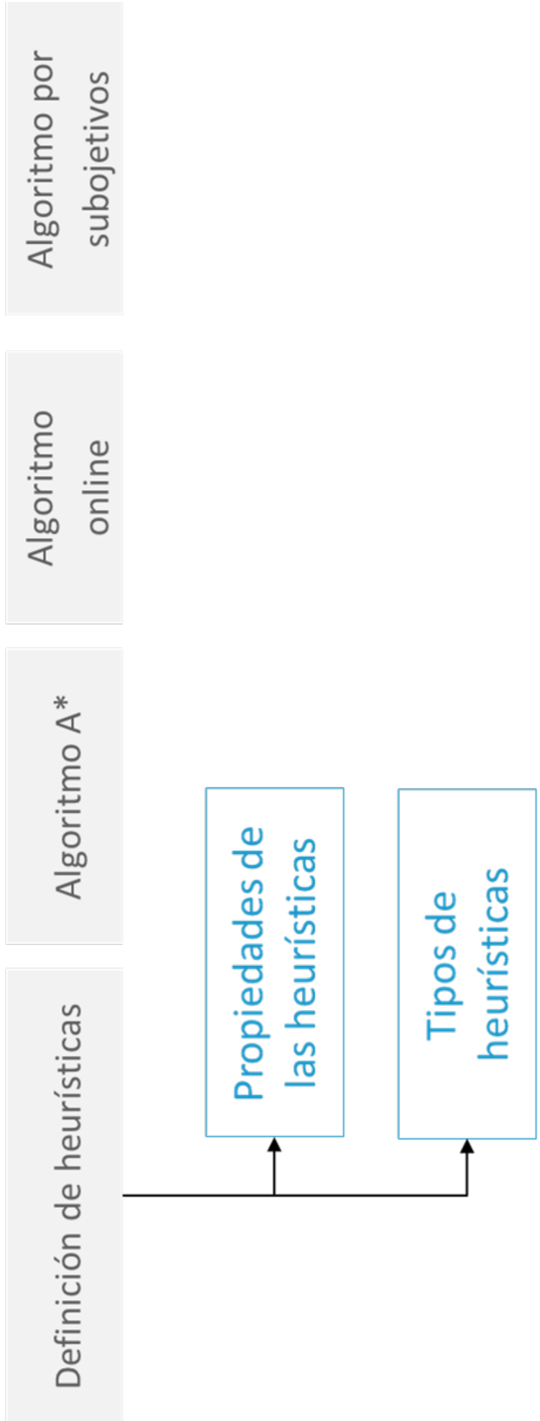
Definición de heurísticas
Algoritmo A*
Algoritmo online
Algoritmo por subojetivos
Propiedades de las heurísticas
Tipos de heurísticas

5.1. ¿Cómo estudiar este tema?

En este tema veremos cómo mejorar las búsquedas en entornos más complejos, donde la expansión de nodos, debido a la complejidad del entorno, puede suponer problemas para realizar la búsqueda.

Exploraremos inicialmente el concepto de **heurística**, como una formalización de la experiencia que se puede proporcionar a un agente que debe resolver un problema y que le permite guiarse a través del espacio de estados.

Con los conceptos de heurística definiremos tres nuevos modelos de búsqueda en espacios no estructurados, que permitirán acelerar el proceso de exploración incluso en entornos reactivos, donde la restricción temporal puede suponer un problema muy restrictivo.

En este tema, nos volveremos a apoyar en el libro de Russell y Norvig: *Inteligencia artificial: un enfoque moderno* (Russell, 2004).

Así, veremos los algoritmos de:

- Búsqueda A*.
- Búsqueda con horizonte limitado.
- Búsqueda online.
- Búsqueda por subobjetivos.

5.2. Tipos de heurísticas

El término «heurística» (del griego: *heuriskein*) significa «encontrar», «descubrir». La heurística surge resolviendo problemas y observando cómo se han resuelto otros.

Podemos definir la heurística como la manera de alcanzar la solución de problemas a través de la evaluación de los progresos alcanzados durante la búsqueda del resultado definitivo.

La heurística es una capacidad típica del ser humano, que le lleva a innovar para alcanzar unos objetivos. En inteligencia artificial, muchos de los algoritmos que se emplean son heurísticos o utilizan reglas heurísticas.

El método heurístico, ya que, como comentamos, se basa en resultados anteriores para lograr nuevos objetivos, puede retornar soluciones verdaderas o falsas, aunque esté correctamente aplicado. En inteligencia artificial, y en las ciencias de la computación en general, el método heurístico se usa en determinadas circunstancias, únicamente cuando no hay una solución óptima con una serie de restricciones de partida.

Los programas heurísticos actúan encontrando algoritmos que proporcionen tiempo de ejecución y soluciones adecuadas. Por ejemplo, en juegos que intentan predecir lo que va a hacer el usuario. Para ello, se basan en la experiencia y en lo que ha hecho el usuario en otras ocasiones.

Un ejemplo de algoritmo heurístico empleado en inteligencia artificial es el encargado de determinar si un email debe ser catalogado como *spam* o como no *spam.* Y es que las reglas, si se emplean de manera independiente, pueden provocar errores de clasificación, pero al ser utilizadas en conjunto, cuando se utilizan muchas reglas heurísticas a la vez, la solución mejora, siendo más robusta y aceptable.

En definitiva, la **heurística en inteligencia artificial representa el conocimiento extraído de la experiencia dentro del dominio del problema**.

Diferenciamos dos tipos de heurística:

- «Fuerte»: pensada para facilitar la resolución del problema, pero no nos garantiza la resolución de este, ni su completitud ni su optimalidad. Es como una «regla de tres» para solucionar un problema.
- «Débil»: buscamos aplicar un método riguroso junto a la información heurística para guiar el proceso de búsqueda. Queremos mejorar el **rendimiento medio** de un método de resolución de problemas, pero no garantiza una mejora en el peor caso.

El concepto de información heurística que aplicaremos a un método de exploración se basa en las **funciones heurísticas**.

La función heurística es dependiente del estado y se usa para evaluar cómo de prometedor es un nodo.

Estas funciones se basan en «el mejor primero», eligiendo el nodo más prometedor para expandir. Una definición simplista es interpretar una heurística como la «distancia» que separa a un nodo de la meta de modo aproximado.

$h(n): n \longrightarrow G$	Coste *real* desde el nodo *n* hasta la meta más cercana.
$h(n)^* : n \longrightarrow G$	Función heurística que estima el valor de *ir desde el nodo n hasta la meta.*

Tabla 1. Funciones de coste real y de coste estimado (heurística).

Por ejemplo, los humanos saben que para ir de Madrid a Barcelona es mejor pasar por Guadalajara que por Toledo; esto es así porque si trazamos una línea recta en el mapa (la distancia euclídea) como estimación de la distancia a Barcelona, veremos que la distancia estimada es mucho menor para Guadalajara que para Toledo.

Función heurística admisible u optimista

Definiremos una función heurística h como admisible si $h(n) \leq h(n)$ para todo n. Por ejemplo, en el dominio del mundo de bloques, una heurística admisible es considerar el número de bloques **descolocados**. O, en el caso de enfrentarnos a un problema de encontrar rutas en una red de carreteras, por ejemplo, estimaríamos la distancia en **línea recta** hasta un nodo meta. Un ejemplo se puede ver en la Figura 1, donde se muestra un grafo que representa una red de carreteras. Las aristas tienen asociado el coste real de ir desde un nodo a otro, por ejemplo, Ir de A a S tiene un costo de 140. La tabla de la derecha presenta el costo estimado para ir desde cualquier nodo al nodo B, que es el nodo objetivo. De este modo, si nos encontramos en la ciudad O y queremos ir a la ciudad B, nuestra heurística estimaría un costo de 380.

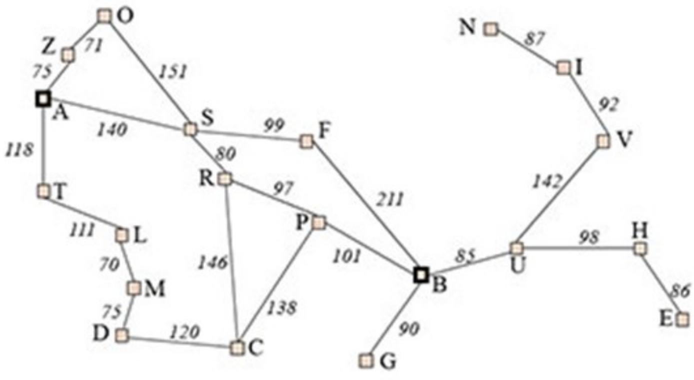

	h^*
A	366
B	0
C	160
D	242
E	161
F	178
G	77
H	151
I	226
L	244
M	241
N	234
O	380
P	98
R	193
S	253
T	329
U	80
V	199
Z	374

Figura 1. Ejemplo esquemático de un grafo que representaría una red de carreteras y su coste estimado para ir hasta el nodo B.

Función heurística consistente

Una heurística consistente es aquella que cumple la propiedad de que el valor de la función de evaluación $f(s) = g(s) + h(s)$ de un hijo nunca es menor que el del padre.

Por ejemplo, si el nodo s' es un sucesor de s y $f(s') < f(s)$, entonces la heurística no será consistente.

Esto implica que con una heurística consistente $f(s)$ es monotónicamente creciente.

Por ejemplo, supongamos una solución de coste 10 y un estado inicial a partir del cual una heurística consistente genera un valor de 6. Sus nodos sucesores podrían tener la siguiente secuencia de valores en la función de evaluación: 6, 6, 6, 7, 7, 8, 8, 8, 9, 10, 10; es decir, el valor de la función de evaluación del hijo es, al menos, tan grande como la del padre.

Dicho de otra forma, el valor heurístico del padre es menor o igual que el valor heurístico del hijo más la distancia del padre al hijo, es decir, $h(s) \leq c(s,s') + h(s')$.

Una heurística consistente siempre es admisible, pero no necesariamente ocurre lo contrario.

Cuestiones

- ¿Cómo se pueden encontrar funciones heurísticas **admisibles y/o consistentes**?
- ¿Cómo se puede distinguir entre «buenas» y «malas» funciones heurísticas?

Diseño de funciones heurísticas

Para el diseño de estas funciones, nos plantearemos el concepto de *planning* de **problemas relajados**. Es decir, aquellos en los que dado un problema real donde tenemos un estado inicial, estado meta, y operadores o acciones, cada una con sus precondiciones (elementos que se deben cumplir en un estado o nodo n, para que la acción se pueda ejecutar sobre dicho nodo n generando un nodo n') y efectos (conjunto de elementos que se deben modificar en el nodo n como resultado de la ejecución del operador o acción)., relajamos los efectos de cada operador quitando cualquier efecto que elimine un elemento del nodo n donde se ejecuta la acción.. En ellos, por tanto, todas las soluciones al problema original también lo son al problema relajado y posiblemente a algunos más.

Partiremos de la idea de usar el coste exacto, $h(n)$, de llegar desde el estado n a un nodo meta para generar en el problema relajado una función heurística $h(n)$ que nos permita resolver el problema original.

El problema lo consideramos relajado porque utilizamos una estimación de $h(n)$.

Por construcción, una función heurística h implementada de esta manera se considera admisible.

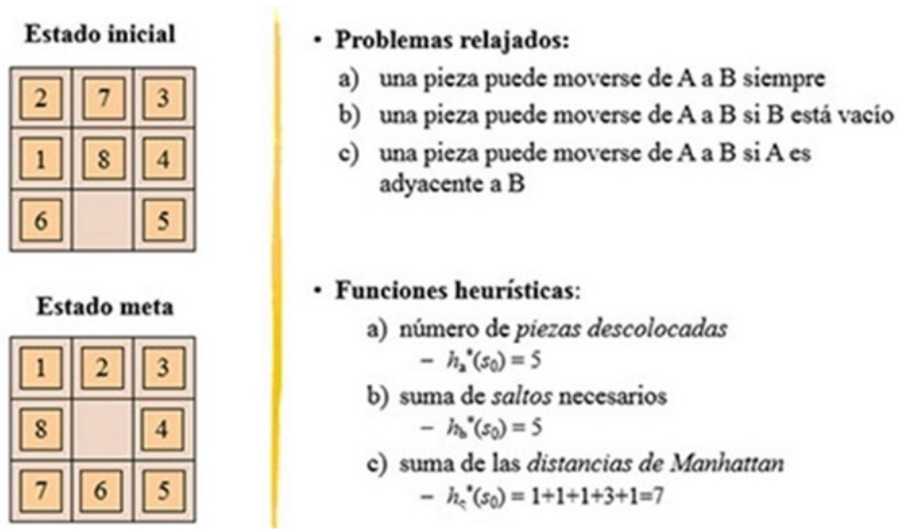

Figura 2. Ejemplo de problemas relajados para el puzle-8.

En la figura 2, podemos ver un ejemplo de problemas relajados para el dominio del puzle-8.

Puzzle-8: es un popular juego que consiste en una matriz de 3x3, en la que se encuentran unas fichas enumeradas del 1 al 8. Adicionalmente, existe una pieza vacía o en blanco. El juego consiste en dado una configuración inicial (Estado inicial) llevar las piezas a una configuración final (Estado meta). En cada turno las únicas piezas que se pueden mover son las piezas adyacentes a la pieza vacía.

En el ejemplo, de la figura 2, se presenta el problema relajado de tres maneras. Por ejemplo, podemos relajar el problema diciendo que a) una pieza puede moverse de A a B directamente. En este supuesto, es como si estuviéramos desarrollando una función heurística basada en a) el número de piezas descolocadas. Otra posible relajación del problema es c) que una pieza se puede mover de A a B si A es adyacente a B. En este caso, es como si desarrolláramos una función heurística basada en c) la distancia en Manhattan, donde realizamos la suma de las distancias de las fichas mal colocadas. La distancia se mide como el número de movimientos necesarios para situar la ficha en la posición final deseada.

Funciones heurísticas y su calidad

Si tenemos dos funciones heurísticas admisibles, $h1$ y $h2$, diremos que $h1$ es más informada que $h2$ si para todo nodo n se cumple que $h1(n) \geq h2(n)$.

De este modo, si $h1$ es más informada que $h2$, entonces el algoritmo que emplee $h2$ expande al menos tantos nodos como aquel que emplee $h1$.

Por tanto, será preferible elegir aquellas funciones que presenten valores de h grandes, siempre que se mantengan admisibles. Si hay varias funciones heurísticas admisibles, elegiríamos aquellas en cada caso que tengan mayor valor en cada momento.

$$h(n) = max(h_1(n), h_2(n), \ldots, h_m(n))$$

5.3. Búsqueda A*

La idea es orientar la búsqueda de una solución en la que las acciones no tienen el mismo coste y desconocemos, *a priori*, el coste de llegar hasta un estado meta, pero podemos estimar, por medio de una función heurística, el coste restante que nos queda desde el nodo actual para alcanzar el nodo meta. Por tanto, nuestro objetivo es minimizar el coste estimado de un camino en el árbol de búsqueda, combinando el coste de llegar al nodo *n* (conocido exactamente por **g(n)**) y el coste aproximado de llegar de este nodo n hasta la meta por medio de la función heurística $h(n)$ *.*

Para nuestro caso, siempre se debe establecer una función heurística $h^{(n)}$ que subestime el coste real h(n) que nos resta para llegar a la meta desde un nodo cualquiera n .

Por lo tanto, contamos con una función de evaluación real que se define como:

$f(n) = g(n) + h(n)$:

coste mínimo que pasa por *n*, es decir, el **coste real** del plan.

Para ello, emplearemos la función de evaluación $f(n)$, que estimará una aproximación de $f(n)$ *:*

$$f(n) = g(n) + h(n)$$

siendo:

- $h(n)$: coste estimado del nodo actual al nodo meta (h(n)=0 si n es un nodo meta).
- $g(n)$: coste real de llegar a n desde el estado inicial.

Por lo tanto, la función de evaluación f*(n) es el coste real de llegar al nodo n más el coste estimado de llegar al nodo meta.

Durante el proceso de búsqueda, emplearemos la estrategia de elegir, entre las hojas del árbol de búsqueda, aquella con un valor f mínimo.

E l **algoritmo A***, se puede explicar brevemente, basándonos en la búsqueda general. Donde deberemos añadir el valor g y f como atributos a cada nodo expandido y ordenar la lista abierta con base a los valores crecientes de f. Por tanto, añadiremos los nuevos nodos en la lista abierta según sus valores crecientes de f.

```
// inicialmente todos los valores de g y f en los nodos son infinitos
Input: Grafo. Estado inicial S0, Estado final G

Definir colaAbierta as colaPrioridad

S0.g ← 0
S0.f ← h(Grafo, S0, G)
colaAbierta ← {S0}

mientras colaAbierta ≠ Ø
    nodo ← extrae el de menor f de colaAbierta
    si G ⊆ nodo
        retornar camino a nodo
    fin si
    sucesores ← expandir(nodo)
    para cada sucessor ∈ sucesores hacer
        tentative g ← nodo.g + c(nodo, sucessor)
        si tentative g < sucessor.g
            sucessor.padre ← nodo
            sucessor.g ← tentative g
            sucesor.f ← sucesor.g + h(Grafo, sucesor, G)
            si sucesor no en colaAbierta
                colaAbierta ← colaAbierta ∪ sucesor

retorna plan vacío o problema sin solución
```

Figura 3. Algoritmo de búsqueda A*.

La figura 3 muestra el algoritmo de búsqueda A. Hay que tener en cuenta que esta implementación del algoritmo no lleva un control de los nodos visitados (lista de nodos cerrados). Aspecto que es bastante importante en una implementación optima del algoritmo A. El estudiante debe estar en la capacidad de buscar y agregar este añadido al algoritmo A ofrecido en la figura 3.

La lista de nodos cerrados se utiliza para controlar los elementos que ya se han visitado. Cuando se evalúa un nodo sucesor (línea 13), siempre se verifica que en el nodo no exista en la lista de nodos cerrados con un menor valor de f, en cuyo caso no lo agregamos en la lista de nodos abiertos (colaAbierta). En caso contrario lo agregaríamos.

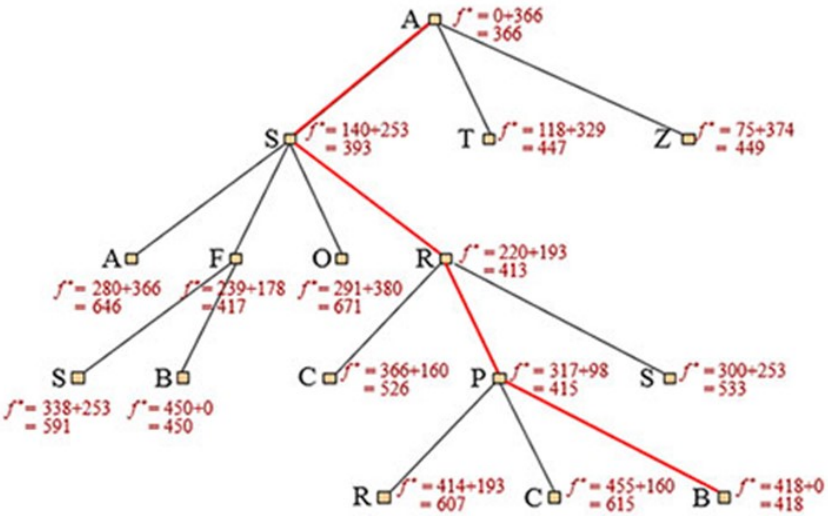

Figura 4. Ejemplo de búsqueda A*.

La **estrategia A*** continúa mientras se produce un crecimiento en el valor de f a lo largo de los caminos del árbol de búsqueda, tal como se muestra en la Figura 4.

Por tanto, si nos alejamos de la meta, g y h, que representan el coste real de ir avanzando hacia la meta y el coste estimado de alcanzar la meta desde la posición actual, crecen, por lo que $f = g + h$, crece en gran medida. En cambio, si nos acercamos a la meta, el valor de f crece poco porque g crece mientras que h disminuye.

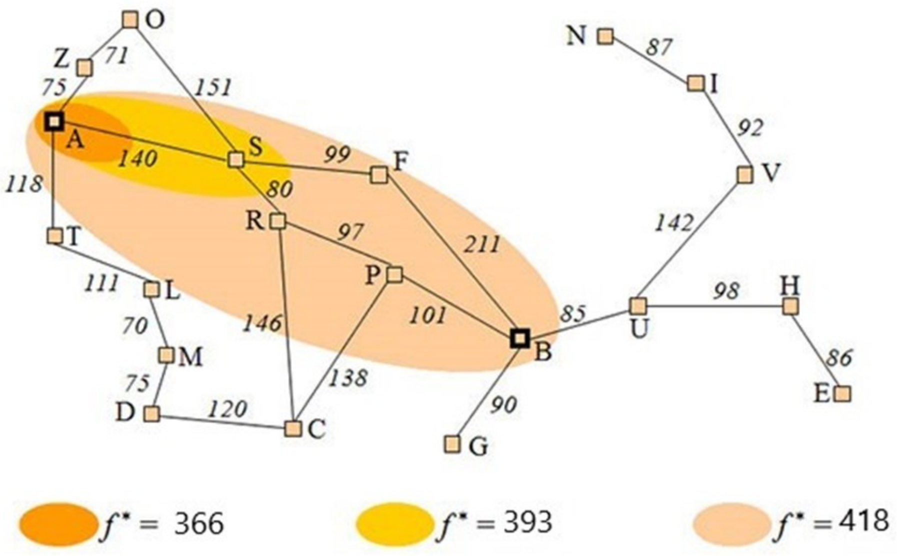

Figura 5. Ejemplo de evolución de los valores de f* a lo largo de una búsqueda.

Si lo comparamos con la búsqueda de coste uniforme, los valores de g crecen a lo largo de todos los caminos del árbol de búsqueda porque en cada paso se suma el coste de un operador (que es un número natural positivo).

En el ejemplo anterior, figuras 4 y 5, los valores de f también crecen a lo largo de todos los caminos del árbol de búsqueda. Pero esto no siempre ha de ser así, tal como se muestra en la siguiente figura 6, donde se ve la diferencia entre el comportamiento esperado del aumento del coste real respecto al coste estimado.

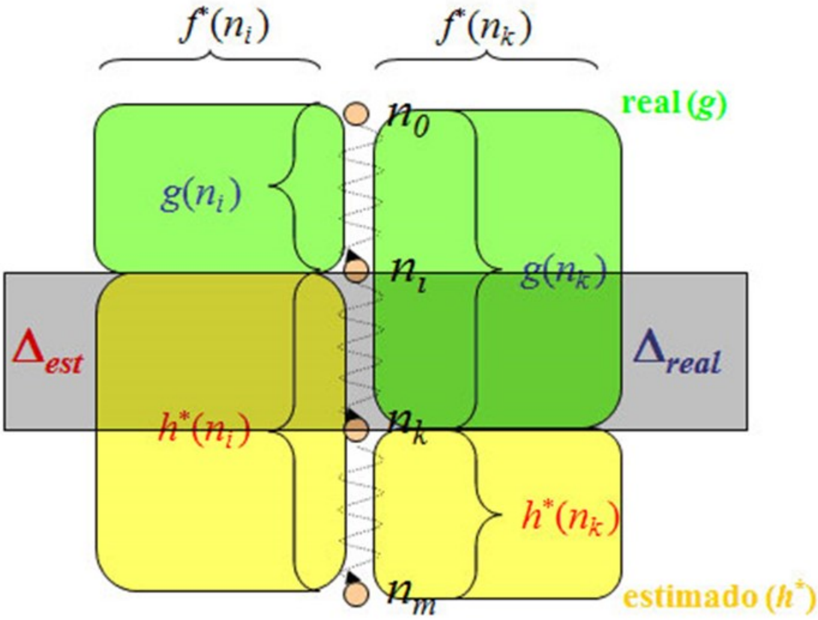

Figura 6. Comportamiento esperado del aumento del coste real respecto al coste estimado.

En un camino del árbol de búsqueda, si un nodo n_k es sucesor (no necesariamente directo) de , entonces el valor de $f(n_i)$ contiene una **estimación** del coste de llegar de n_i a n_k (D_{est}) y $f(n_k)$ el coste real (D_{real}). Es decir, se puede obtener el valor de $f(n_k)$ a partir de $f(n_i)$, sumando D_{real} y restando D_{est}. Es posible que $f(n_k) < f(n_i), si\, D_{est} > D_{real}$.

La función heurística en la que nos apoyemos debe ser admisible.

Análisis del Algoritmo A*

El algoritmo A* es:

- Óptimo: si h es admisible.
- Y completo, en caso de existir una solución, siempre dará con ella.

Presenta una complejidad dependiente del número de nodos expandidos, que depende, a su vez, de la precisión de h , de tal modo que si tuviésemos que la función heurística fuese de perfecta información $(h\,(n) = h(n)\ para\ todos\ los\ nodos\ n)$, la complejidad sería lineal (sin contar la complejidad de computar h). Mientras que, si carecemos de información, $(h\,(n) = 0\ para\ todos\ los\ nodos\ n)$, la búsqueda A degenera en la búsqueda de coste uniforme.

Aun así, suele haber una mejora notable en comparación con métodos no informados.

Por ejemplo, en la figura 7, se muestra una comparativa del número de nodos expandidos en el problema del 8-puzzle de un método no informado con el algoritmo A usando diferentes heurísticas. Suponemos que la profundidad de la solución se encontrase tras **d** niveles.

d	B. no informada (prof. iterativa)	$A^*(h_a)$	$A^*(h_c)$
2	10	6	6
4	112	13	12
6	680	20	18
8	6.384	39	25
10	47.127	93	39
12	3.644.035	227	73
14	—	539	113
16	—	1.301	211
18	—	3.056	363
20	—	7.276	676
22	—	18.094	1.219
24	—	39.135	1.641

Figura 7. Media estimada para cien ejecuciones. Fuente: basado en (Russell, 2004).

5.4. Búsqueda por subobjetivos

El uso de heurísticas puede reducir drásticamente la complejidad de los algoritmos de búsqueda. Por ello es una estrategia que debe considerarse en muchos problemas, ya sea con una aplicación débil o con una aplicación más fuerte.

El Algoritmo A emplea una aplicación «débil» de información heurística. Se usan heurísticas para guiar la búsqueda, no para reducir el espacio de posibles soluciones. Se mantienen propiedades de *completitud* y *optimalidad*.

En muchos casos, se requiere/prefiere una aplicación «fuerte» de heurísticas que reduzca el espacio de búsqueda de forma efectiva (en anchura o profundidad), aunque se corra el riesgo de no explorar posibles soluciones, dado que estas son poco probables. Así, es posible que no se encuentre la mejor solución (no ser óptimos). Pero el objetivo es encontrar soluciones «buenas» (no necesariamente óptimas) y mejorar el rendimiento de forma substancial, aunque la *optimalidad* y completitud no se garanticen.

L a **búsqueda por subobjetivos** tiene como finalidad principal **reducir la complejidad de un problema de búsqueda**. La idea se fundamenta en disminuir la profundidad de las búsquedas, subdividiendo el problema en varios subproblemas más pequeños mediante una heurística fuerte.

Intenta determinar una secuencia de estados intermedios $(i_1, i_2, \ldots, i_n)$ que con mayor probabilidad van a encontrarse en el camino óptimo, ver figura 8. Con estos estados intermedios, realizará búsquedas con un **método base** (amplitud, o profundidad, por ejemplo) desde el estado inicial $s_0 a i_1, de\, i_1 a i_2$, …, y de i_n al estado meta s_m . Por ejemplo, en la Figura 9, vemos el árbol generado para solucionar el subproblema de $s_0 a i_1$, con la búsqueda en amplitud.

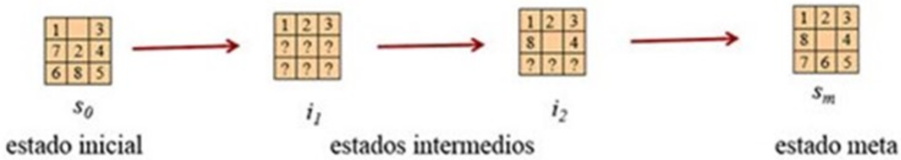

Figura 8. Subobjetivos para el problema de Puzzle-8.

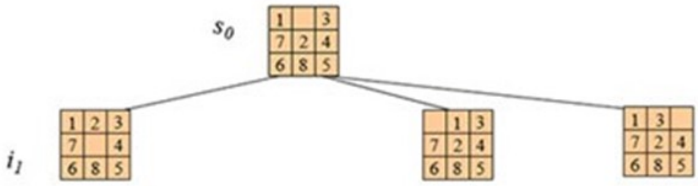

Figura 9. Método base: búsqueda en amplitud camino de s0 a i1.

Otro ejemplo se puede observar en la figura 10, donde se muestra el árbol que soluciona el subproblema de encontrar un camino para ir del sub estado $i_1 a i_2$.

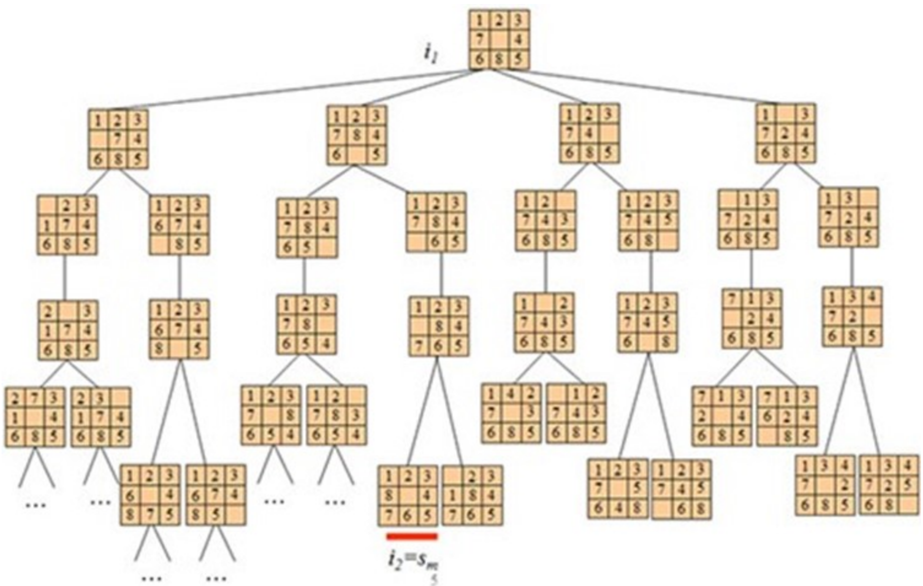

Figura 10. Camino de i1 a i2.

Complejidad de búsqueda por subobjetivos

En esta técnica nos encontramos con que la complejidad en tiempo y espacio depende de condiciones diferentes:

- Complejidad en tiempo: nodos expandidos.
- Complejidad en espacio: nodos abiertos.

En general, si la elección de subobjetivos es buena, se obtiene una mejora en la complejidad, siempre que los caminos entre los pares de subobjetivos estén «más cortos» que la solución global.

Por ejemplo, en la figura 11, se muestra la complejidad algorítmica para un problema cuyo factor de ramificación fuese $b = 3$, la profundidad de la solución fuese $d = 20$ y creásemos $x = 4$ subobjetivos de profundidad $d' = 5$ (el camino encontrado tiene una longitud de 25), y además empleáramos como técnica básica un algoritmo de búsqueda en amplitud.

		General		Ejemplo	
		Bús. prof.	Bús. subob.	Bús. prof.	Bús. subob.
mejor caso:	- tiempo:	$\frac{b^{d}-1}{b-1}$	$(x+1)\frac{b^{d_r}-1}{b-1}$	1.743.392.200	605
	- espacio:	$\frac{b^{d+1}-1}{b-1}$	$(x+1)\frac{b^{d_r+1}-1}{b-1}$	5.230.176.601	1820
peor caso:	- tiempo:	$\frac{b^{d+1}-1}{b-1}-1$	$(x+1)\frac{b^{d_r+1}-1}{b-1}-1$	5.230.176.600	1815
	- espacio:	$\frac{b^{d+2}-1}{b-1}-b$	$(x+1)\frac{b^{d_r+2}-1}{b-1}-b$	15.690.529.801	5450

Figura 11. Estimaciones de complejidad algorítmica.

Análisis de búsqueda por subobjetivos:

Permite reducir de forma substancial la complejidad, especialmente en problemas de planes muy largos. La búsqueda por subobjetivos no es necesariamente completa ni óptima.

Por tanto, es completo si el método base es completo y los subobjetivos se encuentran en el camino que nos permite llegar desde el estado inicial al final. Asimismo, será optimo si el método base es óptimo y los subobjetivos se encuentran ordenados de tal modo que su camino sea el mínimo posible dentro del camino solución.

En el caso de utilizar búsquedas heurísticas como método base (por ejemplo, A), se puede alcanzar una reducción aún mayor de la complejidad, pero puede llegar a ser necesario especificar distintas funciones heurísticas para cada subobjetivo.

5.5. Búsqueda online

En algunos entornos no es posible/útil encontrar un plan completo. Por ejemplo, en entornos reactivos, o en entornos no deterministas o dinámicos, donde no se pueden determinar los resultados de las acciones, o el entorno y/o el estado meta puede cambiar. Por ejemplo: seguir un objeto en movimiento (escalera de Hogwarts).

Tampoco es posible encontrar un plan completo en entornos (parcialmente) inaccesibles, donde se desconoce parte del entorno (estados existentes, resultados de las acciones). Por ejemplo: el dominio de un laberinto donde se conoce parcialmente el laberinto y el mismo se va descubriendo a medida que el agente camina por el laberinto.

Surgen de la necesidad que tienen los agentes reactivos de encontrar una solución en un tiempo muy corto. Esta falta de tiempo para encontrar la solución hace que en muchos casos baste con encontrar una buena acción, no un plan de acción completo bueno.

La idea básica es combinar un paso de búsqueda con un paso de actuación. En la tabla 2, podemos ver una comparación entre los dos tipos de búsqueda, online y offline.

Búsqueda online	Búsqueda offline
Repetir: 1. Percibir entorno. 2. Elegir la «mejor» acción. 3. Ejecutar acción. Fin repetir.	1. Percibir entorno. 2. Buscar plan. 3. Ejecutar plan.

Tabla 2. Comparativa entre la búsqueda online y offline.

A continuación, vamos a ver, los siguientes tipos de búsqueda online:

- Búsqueda por ascenso de colinas.
- Búsqueda por horizonte.
- Optimización mediante búsqueda online.

Búsqueda por ascenso de colinas *(hill climbing)*

Tiene como idea inicial disminuir la profundidad del árbol de búsqueda e intentar llevar a cabo la acción que parece más prometedora en cada momento, repitiendo el ciclo percepción/acción de forma continua, tal como se muestra en la figura 12.

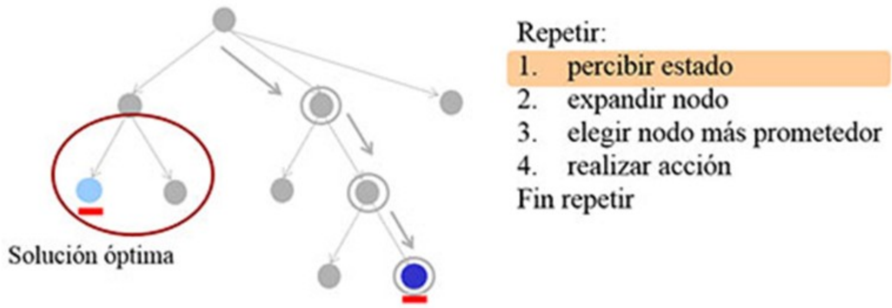

Figura 12. Comportamiento de la búsqueda por ascenso de colinas.

El algoritmo de búsqueda por ascenso de colinas (Skiena, 2010), ver figura 13, emplea una función heurística para calcular la distancia estimada al nodo meta más cercano desde el nodo $n, h(n)$; por otro lado, debe retornar el estado actual del problema por medio de un mecanismo de percepción $(percibir(entorno))$. En un estado determinado por el nodo n , debe evaluar cuál de las posibles acciones es la mejor por medio de la estimación heurística de las opciones presentes $(evaluar(n,h))$. Una vez decidida cuál es la mejor acción, la ejecutaremos dentro del entorno.

```
{búsqueda ascenso de colinas}
Repetir
    nodo ← percibir(entorno)
    Si meta?(nodo) entonces
        devolver(positivo)
    sucesores ← expandir(nodo)
    Si vacia?(sucesores) entonces
        devolver(negativo)
```

$$\text{mejor} \leftarrow \underset{n \in sucesores}{\arg\min}\left[evaluar(n, h^{*})\right]$$

```
    a ← acción(n,mejor)
    ejecutar(a, entorno)
    Fin {repetir}
```

Figura 13. Algoritmo general de la búsqueda por ascenso de colinas.

Análisis de búsqueda por ascenso de colinas

En general, **no se puede asegurar *optimalidad* ni completitud**. Pero suele producir resultados mejores, sobre todo en los casos en los que no existan bucles y la función heurística sea buena. Si h es completa $(h = h)$, entonces es **óptimo y completo**. Hay que vigilar la eliminación de ciclos y eliminar los estados repetidos.

Este algoritmo es utilizado para resolver problemas donde se debe encontrar un óptimo local (una solución que no puede ser mejorada considerando una configuración de la vecindad) pero no garantiza encontrar la mejor solución posible (el óptimo o máximo global) de todas las posibles soluciones (el espacio de búsqueda). Aun así, esto se puede remediar utilizando reinicios (búsqueda local repetida), o esquemas más complejos basados en iteraciones (Lourenço, 2019), como búsqueda local iterada, en memoria, como optimización de búsqueda reactiva

(Battiti, Brunato, & Mascia, Reactive Search and Intelligent Optimization, 2008) y/o búsqueda tabú (Battiti & Tecchiolli, The reactive tabu search, 1994).

Búsqueda con horizonte

Hacemos una expansión de los nodos hasta la profundidad *k* (horizonte) y realizamos aquella acción que es más prometedora de todas las acciones de ese nivel, repitiendo de forma continua hasta que encontramos una solución dentro del horizonte de búsqueda.

El algoritmo general arranca en un estado s, desde el cual aplicamos una búsqueda no informada de profundidad k, que puede ser suspendida en los nodos meta. De las hojas (H) adquiridas en el nivel k, obtenemos la mejor empleando una función heurística h, de tal modo que optaremos por aquella acción que nos lleve a la hoja de menor coste estimado. Repetiremos este proceso hasta alcanzar la meta. A continuación, en las figuras 14, 15 y 16, se muestra un ejemplo de tres pasos.

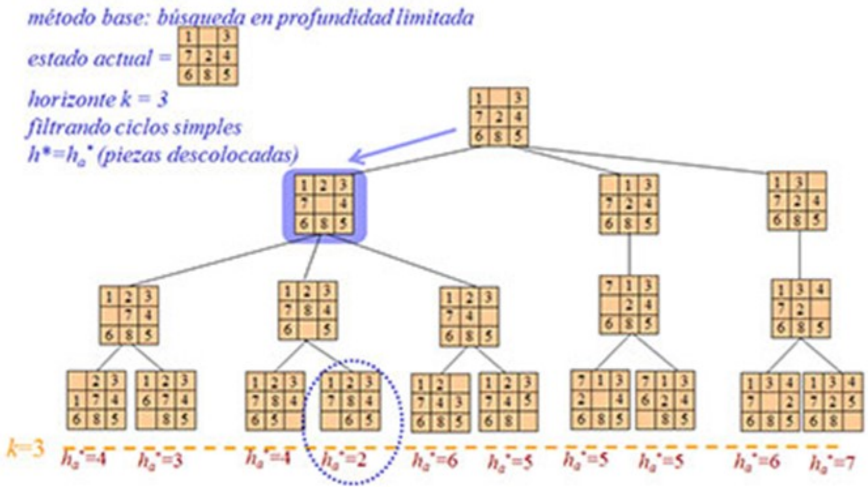

Figura 14. Ejemplo de búsqueda en profundidad limitada (paso 1).

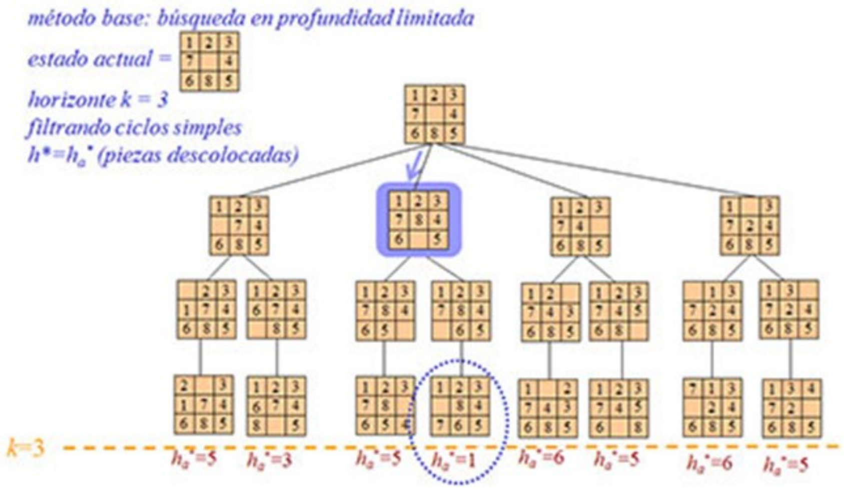

Figura 15. Ejemplo de búsqueda en profundidad limitada (paso 2).

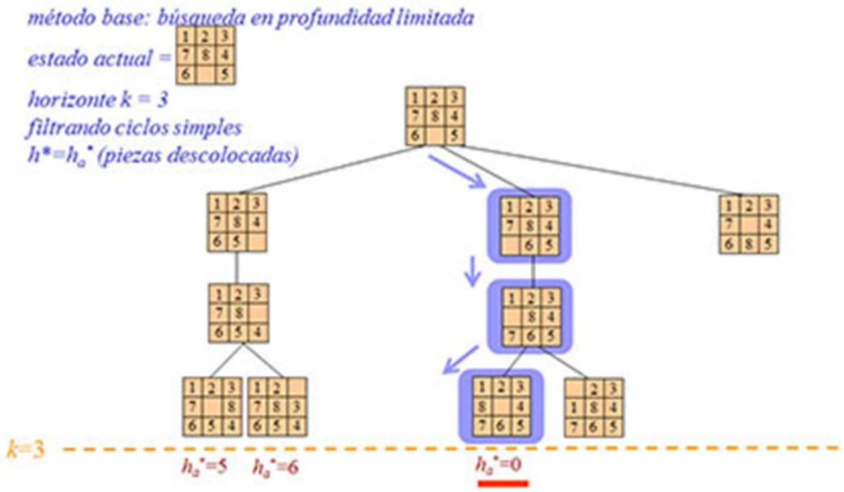

Figura 16. Ejemplo de búsqueda en profundidad limitada (paso 3, final).

Análisis de búsqueda con horizonte

En general, no se puede asegurar *optimalidad* ni completitud, dado que esta está ligada directamente con la función heurística. En el caso de tener una h **completa** $(h = h)$ **, entonces es óptimo y completo**.

La búsqueda por ascenso de colinas es un subtipo de la búsqueda con horizonte (horizonte = 1). El aumento del horizonte de exploración permite evitar bucles de longitud menor que k.

Optimización mediante búsqueda online

Un subtipo de problemas a los que se puede aplicar con éxito las búsquedas online (horizonte/ascenso de colinas) es el de los problemas de optimización, es decir, aquellos en los que tenemos una función objetivo que deseamos alcanzar. En este tipo de problemas no necesitamos obtener el valor máximo/mínimo de la función que deseamos alcanzar, sino que nos basta con el valor que más se aproxime a dicho óptimo.

El camino para llegar al estado buscado puede ser irrelevante (coste 0). Algunos ejemplos: juegos lógicos y de configuración, n-Reinas.

En los problemas de optimización con funciones heurísticas estimas el coste del camino que parte del estado actual y va hasta el nodo meta más próximo, midiendo la calidad de un nodo con respecto a una función de evaluación objetivo.

5.6. Referencias bibliográficas

Battiti, R., & Tecchiolli, G. (1994). The reactive tabu search. *ORSA Journal on Computing, 6* (2): 126-140.

Battiti, R., Brunato, M., & Mascia, F. (2008). Reactive Search and Intelligent Optimization. Springer Verlag ISBN 978-0-387-09623-0 archivado desde el original el 16 de marzo de 2012.

Lourenço, H. R. (2019). *Iterated local search: Framework and applications.* Springer, Cham.

Russell, S. y. (2004). *Inteligencia Artificial: Un Enfoque Moderno.* Madrid: Pearson Educación.

Skiena, S. S. (2010). *The Algorithm Design Manual, Softcover reprint of hardcover 2nd.* Springer.

Enfoque de búsqueda en tiempo real

Fernández, M. O. (1998). *Algoritmos de búsqueda heurística en tiempo real. Aplicación a la navegación en los juegos de vídeo.* Universidad Nacional del Centro de la Provincia de Buenos Aires, Argentina. Recuperado de: http://www.exa.unicen.edu.ar/catedras/aydalgo2/docs/TFca06aCompleto.pdf

En este trabajo encontrarás información sobre cómo plantear una búsqueda online en tiempo real en un entorno como podría ser el de los videojuegos.

Sesgos cognitivos

González, J. (1 de enero de 2013). Heurísticos y sesgos cognitivos: los atajos de la mente. Recuperado de: http://jesusgonzalezfonseca.blogspot.com.es/2013/01/heuristicos-y-sesgos-cognitivos-los.html

Aquí se presenta una discusión sobre la integración de funciones heurísticas y de sesgo cognitivo en el que nos basamos a la hora de realizar estimaciones optimistas. Estos sesgos son importantes a la hora de evaluar nuestra neutralidad en las estimaciones, tanto para realizar algoritmos de búsqueda como para modelizar cualquier tipo de toma de decisiones.

1. En el algoritmo A* se usan heurísticas para:

   A. Reducir el espacio de posibles soluciones.

   B. Guiar la búsqueda.

   C. Se emplea una aplicación débil de información heurística.

2. La aplicación fuerte de heurísticas hace que:

   A. Se reduzca el espacio de búsqueda.

   B. Siempre encuentre la mejor solución.

   C. Tiene como objetivo encontrar soluciones buenas, aunque no sean necesariamente óptimas.

3. El objetivo de la búsqueda por subobjetivos es:

   A. Ampliar la complejidad de un problema de búsqueda.

   B. Reducir la complejidad de un problema de búsqueda.

   C. Subdividir el problema en varios problemas pequeños mediante la aplicación de una heurística fuerte.

4. En cuáles de los siguientes entornos no es posible o útil encontrar un plan completo:

   A. Entornos no deterministas.

   B. Entonos inaccesibles.

   C. Agentes reactivos que actúan de forma rápida o con objetivo continuo.

5. La idea básica de la búsqueda online es:

   A. La combinación de un paso de búsqueda con un paso de actuación.

   B. Realizar solo pasos de búsqueda de manera sucesiva.

   C. Ninguna de las respuestas anteriores es correcta.

6. La idea que subyace en la búsqueda por ascenso de colinas es:

A. Reducir profundidad del árbol expandido y realizar siempre la acción más prometedora.

B. Expandir el árbol solo un nivel, realizar la acción hacia el mejor nodo y repetir el ciclo percepción-acción de manera continuada.

C. Ninguna de las respuestas anteriores es correcta.

7. En la búsqueda por ascenso de colinas, se puede conseguir completitud si:

A. El conjunto de posibles estados es infinito.

B. El conjunto de posibles estados es finito.

C. Se eliminan todos los estados por los que se ha ido pasando.

8. En la búsqueda con horizonte:

A. La primera acción de un plan que lleva a un nodo con una evaluación heurística óptima tiene una buena probabilidad de pertenecer al camino óptimo.

B. Son reiteradas acciones de un plan las que llevan a un nodo con una evaluación heurística óptima.

C. Asegura que hay *optimalidad* y completitud.

9. En un problema de optimización:

A. El camino para llegar al estado siempre es relevante.

B. No busca un estado exacto, sino que se acerque al máximo objetivo.

C. El objetivo es encontrar el mejor estado según una función objetivo.

10. La búsqueda online para optimización es útil para problemas con:

A. Número infinito de estados.

B. Número finito de estados.

C. Tanto para número infinito como finito de estados.